



Rapport détaillé du projet de prévision des ventes Rossmann

Présentation générale

Ce projet a pour objectif de concevoir une application complète de prévision des ventes pour un réseau de magasins, à partir de données historiques de type Rossmann, puis de transformer cette logique analytique en un outil interactif exploitable dans un tableau de bord Streamlit. Le système s'appuie sur des fichiers de données de ventes, des informations magasin et des sorties de prédiction par lot, ce qui montre une chaîne de traitement allant de la donnée brute jusqu'à la restitution métier.^[1]

Le projet ne se limite pas à entraîner un modèle de machine learning. Il inclut aussi la préparation des données, la construction de variables temporelles, la comparaison de plusieurs approches de prévision, la génération de fichiers de sortie et la visualisation des résultats sous forme de dashboard orienté décision.^[1]

Contexte métier

Dans un contexte retail, prévoir le chiffre d'affaires futur est essentiel pour piloter les stocks, planifier les promotions, anticiper les besoins humains et améliorer la prise de décision commerciale. Une prévision fiable permet d'estimer les ventes par magasin et par date, puis d'identifier les variations dues au calendrier, à l'ouverture du magasin ou aux opérations promotionnelles.^[1]

Le cas Rossmann est particulièrement adapté à ce type de problématique, car les ventes dépendent fortement de facteurs calendaires et commerciaux. Le fichier de prédictions montre explicitement des colonnes comme Store, DayOfWeek, Date, Open, Promo, StateHoliday, SchoolHoliday et PredictedSales, ce qui confirme que le projet cherche à relier le comportement des ventes à la structure du temps et au contexte magasin.^[1]

Objectifs du projet

Le premier objectif est de prédire les ventes futures de magasins à partir de variables explicatives disponibles au moment de la décision. Ces variables incluent notamment le jour de la semaine, l'état d'ouverture, les promotions, les vacances scolaires et les caractéristiques du magasin.^[1]

Le deuxième objectif est de rendre la prévision accessible à un utilisateur non technique grâce à une interface simple. Le projet vise ainsi une double valeur : une valeur analytique, par la

qualité de la modélisation, et une valeur opérationnelle, par l'intégration dans une application interactive de démonstration et d'aide à la décision. ^[2] ^[1]

Le troisième objectif est de comparer plusieurs approches de modélisation, en particulier un modèle tabulaire de type XGBoost et un modèle de série temporelle comme Prophet. Cette comparaison permet d'évaluer les compromis entre précision, simplicité d'interprétation et capacité à projeter le futur. ^[1]

Jeux de données mobilisés

Le projet s'organise autour de plusieurs fichiers complémentaires. Le fichier `store.csv` contient les informations structurelles des magasins, tandis que `test.csv` sert de base pour les prédictions hors apprentissage, et `rossmann_predictions_batch-1.csv` représente une sortie de prédiction enrichie d'une colonne `PredictedSales`. ^[1]

Le fichier de sortie montre que chaque ligne correspond à une combinaison d'identifiant, de magasin et de date avec des indicateurs de contexte. La présence de séquences de dates comme 2015-09-17, 2015-09-16, 2015-09-15, 2015-09-14, 2015-09-10 et 2015-09-09 indique que le modèle a été appliqué sur un jeu structuré chronologiquement, avec un comportement quotidien et multi-magasins. ^[1]

Compréhension des variables

La variable cible du projet est le chiffre d'affaires à prévoir, matérialisé dans la sortie par `PredictedSales`. Cette variable représente l'estimation finale produite par le modèle pour chaque observation. ^[1]

Plusieurs variables d'entrée jouent un rôle déterminant. `Store` identifie le magasin, `DayOfWeek` porte l'effet hebdomadaire, `Date` positionne l'observation dans le temps, `Open` indique si le magasin est ouvert, `Promo` signale une promotion active, `StateHoliday` capture les jours fériés et `SchoolHoliday` les vacances scolaires. ^[1]

Ces variables traduisent des mécanismes métier cohérents. Par exemple, un magasin fermé doit logiquement produire un chiffre d'affaires nul ou très faible, tandis qu'une promotion peut modifier temporairement le niveau de ventes. Les effets calendaires permettent en outre de distinguer les comportements hebdomadaires et les ruptures liées aux jours particuliers. ^[1]

Démarche globale du projet

La construction du projet suit une démarche data science classique, structurée en étapes successives. Cette démarche comprend le chargement des données, l'analyse exploratoire, le nettoyage, la préparation des variables, l'entraînement du modèle, la prédiction, l'évaluation et la mise à disposition dans un dashboard. ^[1]

Cette organisation est importante, car elle montre qu'un modèle performant ne résulte pas seulement du choix de l'algorithme. La qualité finale dépend aussi de la cohérence des données, de la manière de traiter la variable date, de la construction des variables explicatives et de la capacité à présenter le résultat de façon utile pour l'utilisateur final. ^[1]

Étape 1 : chargement et inspection initiale

La première étape consiste à charger les fichiers source et à vérifier leur structure. Dans ce type de projet, cela signifie contrôler les noms de colonnes, les types de variables, la présence de doublons, les valeurs manquantes et la cohérence du calendrier.^[1]

L'inspection initiale permet aussi d'identifier les variables directement disponibles pour la prévision et celles qui devront être construites. Dans le fichier de sortie, la présence d'une colonne Date explicite montre que le temps est une composante centrale et qu'il est indispensable de le traiter avec rigueur dès le début du pipeline.^[1]

Étape 2 : nettoyage des données

Le nettoyage des données vise à garantir que les informations transmises au modèle sont cohérentes. Cette étape inclut généralement la conversion correcte des dates, le traitement des valeurs manquantes, la correction d'éventuelles incohérences dans les statuts d'ouverture et la normalisation des formats des variables catégorielles.^[1]

Dans un projet retail, une erreur fréquente concerne le mauvais traitement du calendrier. Le fichier de sortie montre que les dates historiques ont été conservées dans certaines analyses par lot, ce qui souligne l'importance de distinguer clairement une prédiction sur données passées d'une véritable projection future.^[1]

Étape 3 : analyse exploratoire

L'analyse exploratoire sert à comprendre la distribution des ventes et les facteurs qui les influencent. Dans ce contexte, elle permet de vérifier si certaines journées ont des comportements spécifiques, si les promotions ont un effet visible, ou si certains magasins présentent des niveaux de ventes structurellement plus élevés que d'autres.^[1]

L'étude des relations entre Open, Promo et PredictedSales est particulièrement importante. Le fichier de sortie contient des cas où Open vaut 0 et où les prédictions sont très faibles ou nulles, ce qui est cohérent avec la logique métier et constitue un premier signal de validité du pipeline.^[1]

Étape 4 : ingénierie des variables

L'ingénierie des variables est l'une des étapes les plus importantes du projet. La colonne Date ne doit pas être utilisée uniquement comme une chaîne de texte ; elle doit être transformée en attributs plus informatifs comme l'année, le mois, le jour, le numéro de semaine, le jour de la semaine, le début ou la fin de mois et d'autres repères calendaires.^[1]

Cette transformation permet au modèle de détecter des motifs récurrents. Un modèle tabulaire comme XGBoost exploite beaucoup mieux les structures calendaires lorsqu'elles sont explicitement fournies sous forme de variables séparées plutôt que cachées dans une date brute.^[1]

D'autres variables peuvent également être construites, comme des indicateurs de fermeture, des agrégats par magasin, ou des variables dérivées de promotion. Cette étape donne au modèle

plus de contexte et augmente sa capacité à apprendre des relations non linéaires entre la situation d'un magasin et son niveau de ventes. ^[1]

Étape 5 : fusion des sources

Le projet implique la combinaison de plusieurs fichiers. Les informations propres aux magasins doivent être rapprochées des lignes de ventes ou des lignes à prédire afin d'enrichir chaque observation avec des attributs structurels comme le type de magasin ou la distance à la concurrence. ^[1]

Cette fusion est une étape critique, car un mauvais appariement entre les identifiants de magasin fausserait toute la prévision. Une fois la fusion réalisée, chaque ligne représente une vision complète d'un magasin à une date donnée, avec ses variables temporelles, commerciales et structurelles. ^[1]

Étape 6 : choix du modèle principal

Le projet s'appuie d'abord sur une logique de machine learning supervisé adaptée aux données tabulaires, avec un modèle de type XGBoost. Ce choix est pertinent, car les données combinent des variables numériques, binaires, catégorielles et temporelles dérivées, que ce type d'algorithme gère efficacement. ^[1]

XGBoost est particulièrement intéressant pour ce projet parce qu'il capte bien les relations non linéaires et les interactions complexes. Il est utile lorsque les ventes ne dépendent pas d'un seul facteur, mais d'une combinaison de calendrier, de promotion, d'ouverture et de spécificités magasin. ^[1]

Étape 7 : logique série temporelle

Au-delà de XGBoost, le projet explore aussi une approche orientée séries temporelles avec Prophet. Cette approche est mieux adaptée lorsque l'on cherche à projeter une courbe future directement à partir du comportement historique, en isolant tendance et saisonnalités. ^[1]

La comparaison entre ces deux approches est un point fort du projet. XGBoost est souvent plus flexible si les variables sont bien préparées, tandis que Prophet est plus intuitif pour représenter visuellement la dynamique temporelle et produire une projection continue dans le futur. ^[1]

Étape 8 : séparation apprentissage et prévision

Une distinction essentielle du projet concerne la différence entre prédire sur des lignes historiques et prévoir réellement le futur. Le fichier `rossmann_predictions_batch-1.csv` contient des dates anciennes comme 2015-09-17 et 2015-09-16, ce qui signifie que le lot traité n'était pas un calendrier futur recréé dynamiquement mais un jeu de lignes déjà datées. ^[1]

Cette distinction doit être explicitement présentée dans le rapport. Une inférence sur données historiques sert surtout à tester le pipeline ou à produire des estimations sur un fichier existant, tandis qu'une prévision future exige de générer de nouvelles dates, puis d'attribuer les variables de contexte correspondantes avant de lancer l'inférence. ^[1]

Étape 9 : prédiction par lot

La prédiction par lot permet de traiter un grand nombre de lignes d'un seul coup et d'exporter un fichier résultat. Le fichier de sortie joint montre exactement ce mécanisme : la table finale reprend les variables du jeu d'entrée et ajoute PredictedSales comme résultat du modèle. ^[1]

Cette étape est très utile sur le plan opérationnel, car elle permet à un utilisateur d'importer un fichier, de lancer les prédictions et de récupérer un CSV exploitable. Elle constitue un pont entre la logique analytique et l'usage métier concret. ^[1]

Étape 10 : projection future

La projection future est la partie la plus stratégique du projet. Elle consiste à construire un calendrier à partir d'une date de départ, sur un horizon donné, puis à calculer les ventes prévues pour chaque jour et chaque magasin ciblé. ^[1]

Pour obtenir une prévision du futur, il ne suffit pas de reprendre les anciennes dates d'un fichier test. Il faut générer de nouvelles dates cohérentes, appliquer des règles métier sur l'ouverture ou les promotions, puis laisser le modèle estimer le chiffre d'affaires jour après jour. ^[1]

Étape 11 : visualisation et dashboard

Le projet intègre une application Streamlit afin de rendre les résultats lisibles et interactifs. Cette couche de restitution transforme les sorties modèles en tableaux, indicateurs et graphiques temporels compréhensibles par un utilisateur final. ^[2] ^[1]

La visualisation joue un rôle central dans l'interprétation. Une courbe des ventes prévues permet de repérer immédiatement les tendances, les pics liés aux promotions, les creux des jours fermés et les variations hebdomadaires. Ce type de graphique est beaucoup plus parlant qu'un simple tableau de chiffres. ^[1]

Architecture fonctionnelle de l'application

L'application a été pensée sous forme de plusieurs modules complémentaires. D'après la logique décrite dans les échanges et les sorties disponibles, cette architecture comprend une page d'accueil, un simulateur unitaire, une analyse par lot, une projection future sur plusieurs mois et une comparaison de modèles. ^[2] ^[1]

Cette organisation modulaire facilite la maintenance et améliore l'expérience utilisateur. Chaque page correspond à un besoin précis : tester une situation, prédire un fichier complet, observer une courbe future ou comparer deux approches de modélisation. ^[2]

Interprétation des résultats

L'interprétation des prédictions doit toujours tenir compte du contexte. Une valeur de PredictedSales n'est jamais absolue ; elle dépend du magasin, du jour, de l'état d'ouverture et des variables commerciales présentes dans la ligne correspondante. ^[1]

Le fichier de sortie montre également quelques valeurs nulles ou négatives proches de zéro sur certaines observations. Cela rappelle qu'une étape de post-traitement peut être nécessaire pour contraindre les prévisions dans un domaine réaliste, par exemple en forçant les valeurs négatives à zéro lorsqu'elles n'ont pas de sens métier. ^[1]

Forces du projet

Le projet présente plusieurs forces majeures. Il couvre l'ensemble de la chaîne data, depuis les fichiers sources jusqu'à une interface de restitution, ce qui en fait une application complète plutôt qu'un simple notebook de modélisation. ^{[2] [1]}

Il montre aussi une bonne compréhension des spécificités du retail. Les variables utilisées, la gestion du calendrier, l'importance de l'ouverture et des promotions, ainsi que la volonté de comparer un modèle tabulaire et un modèle temporel, traduisent une approche sérieuse et cohérente du problème métier. ^[1]

Enfin, la présence d'un export CSV de prédiction prouve que le projet a une dimension opérationnelle. Il ne reste pas au stade expérimental ; il produit des livrables concrets pouvant être consultés, transmis ou réutilisés dans un autre environnement. ^[1]

Limites et points de vigilance

Le principal point de vigilance concerne la gestion des dates. Le fichier de prédiction par lot montre que les anciennes dates ont été conservées, ce qui peut être correct pour un test sur données historiques, mais devient problématique si l'objectif affiché est une prévision du futur. ^[1]

Un autre point de vigilance concerne la cohérence des sorties faibles ou négatives. Certaines lignes du fichier montrent des prédictions proches de zéro voire légèrement négatives, ce qui signifie qu'un contrôle supplémentaire est utile pour garantir une interprétation métier robuste. ^[1]

Le projet dépend aussi fortement de la qualité de l'ingénierie des variables. Si les informations temporelles ou les variables issues du magasin sont mal préparées, même un modèle performant ne pourra pas généraliser correctement. ^[1]

Enseignements méthodologiques

Ce projet montre qu'en data science, la performance ne dépend pas uniquement de l'algorithme choisi. Les étapes en amont, comme le nettoyage, la conversion des dates, la fusion des jeux de données et la construction des variables, ont un impact décisif sur la qualité finale. ^[1]

Il montre également qu'un bon projet analytique doit distinguer trois niveaux : la modélisation, la restitution et l'usage métier. Ici, le modèle produit une estimation, le dashboard la rend lisible, et l'utilisateur l'exploite pour piloter l'activité commerciale. ^{[2] [1]}

Recommandations d'amélioration

Plusieurs améliorations peuvent renforcer le projet. La première consiste à séparer nettement les modes "analyse historique" et "prévision future" afin d'éviter toute confusion sur la signification des dates affichées dans les exports. ^[1]

La deuxième consiste à ajouter des contrôles de qualité automatiques sur les sorties, notamment pour empêcher les valeurs négatives ou signaler les lignes incohérentes. Une troisième piste est d'enrichir la comparaison entre Prophet et XGBoost avec des indicateurs de performance plus visibles dans le dashboard. ^[1]

Il est également pertinent d'améliorer encore la visualisation en affichant les intervalles d'incertitude, les agrégations hebdomadaires ou mensuelles, et des filtres plus intuitifs par magasin ou période. Ces éléments renforceraient la lisibilité métier et la qualité de la démonstration. ^{[2] [1]}

Conclusion

Ce projet constitue une application de prévision des ventes complète, bien structurée et pertinente pour un contexte retail. Il mobilise des données magasin, des variables calendaires, un modèle de machine learning, une logique de série temporelle et une interface Streamlit afin de transformer la donnée en outil d'aide à la décision. ^{[2] [1]}

Sa valeur principale réside dans sa double dimension : analytique et opérationnelle. D'un côté, il met en œuvre les étapes essentielles d'un projet data sérieux ; de l'autre, il fournit une restitution exploitable sous forme de dashboard et de fichiers de sortie prêts à l'emploi. ^{[2] [1]}

Le rapport met aussi en évidence un point méthodologique fondamental : prédire sur un fichier daté du passé n'est pas la même chose que prévoir le futur. Cette clarification, déjà visible dans le contenu du fichier de sortie, constitue l'un des enseignements majeurs du projet et un axe essentiel pour sa consolidation finale. ^[1]

**

1. rossmann_predictions_batch-1.csv
2. une-version-Streamlit-API-pour-la-demonstration.pdf
3. Notebook-Google-Colab-complet-Projet-Rossmann-St-1.pdf
4. une-API-operationnelle-avec-le-meilleur-modele.pdf